

Martin-Luther-Universität Halle-Wittenberg  
Juristische und Wirtschaftswissenschaftliche  
Fakultät

Wirtschaftswissenschaftlicher Bereich

## **Formelsammlung Statistik**

für die Veranstaltungen Statistik I und Statistik II  
im Grundstudium bzw. Bachelorstudium

Prof. Dr. Claudia Becker  
Lehrstuhl für Statistik



# Inhaltsverzeichnis

<b>1</b>	<b>Summenzeichen</b>	<b>5</b>
<b>2</b>	<b>Häufigkeitsverteilungen</b>	<b>5</b>
2.1	Absolute Häufigkeit . . . . .	5
2.2	Relative Häufigkeit . . . . .	5
2.3	Histogramm . . . . .	5
2.4	Empirische Verteilungsfunktion . . . . .	5
<b>3</b>	<b>Lagemaße</b>	<b>5</b>
3.1	Lagemaße I: Daten als Urliste . . . . .	5
3.1.1	Arithmetisches Mittel . . . . .	5
3.1.2	Geometrisches Mittel . . . . .	6
3.1.3	Median (Zentralwert) . . . . .	6
3.1.4	Modus (Modalwert) . . . . .	6
3.1.5	p-Quantile ( $0 < p < 1$ ) . . . . .	6
3.2	Lagemaße II: Urliste, unklassierte und klassierte Häufigkeitsverteilung	7
<b>4</b>	<b>Streuungsmaße</b>	<b>8</b>
4.1	Spannweite (Range) . . . . .	8
4.2	Interquartilsabstand . . . . .	8
4.3	Mediane absolute Abweichung vom Median (MAD) . . . . .	8
4.4	Empirische Varianz I: Daten als Urliste . . . . .	8
4.5	Empirische Varianz II: Urliste, unklassierte und klassierte Häufigkeitsverteilung . . . . .	9
4.6	Stichprobenvarianz . . . . .	10
4.7	Standardabweichung . . . . .	10
4.8	Standardisierung . . . . .	10
4.9	Variationskoeffizient . . . . .	10
<b>5</b>	<b>Schiefemaße</b>	<b>10</b>
5.1	Lageregeln . . . . .	10
5.2	Schiefekoeffizient nach Pearson (Momentenkoeffizient) . . . . .	10
<b>6</b>	<b>Konzentrationsmaße</b>	<b>10</b>
6.1	Relative Konzentration . . . . .	10
6.1.1	Gini-Koeffizient . . . . .	10
6.1.2	Lorenzkurve . . . . .	12
6.2	Absolute Konzentration . . . . .	12
<b>7</b>	<b>Mehrdimensionale Merkmale</b>	<b>12</b>
7.1	Kontingenztafeln . . . . .	12
7.2	Bedingte Verteilungen . . . . .	12
7.2.1	Bedingte Verteilung von X . . . . .	12
7.2.2	Bedingte Verteilung von Y . . . . .	12
7.2.3	Rekonstruktion der gemeinsamen Häufigkeiten . . . . .	13
7.3	Zusammenhangsanalyse in Kontingenztafeln . . . . .	13
7.3.1	Hypothetische absolute Häufigkeit (bei Unabhängigkeit der Merkmale) . . . . .	13
7.3.2	Chi-Quadrat Koeffizient . . . . .	13
7.3.3	Kontingenzkoeffizient . . . . .	13
7.3.4	Korrigierter Kontingenzkoeffizient . . . . .	13
7.4	Zusammenhangsmaße bei metrischen Merkmalen . . . . .	13
7.4.1	Korrelationskoeffizient nach Bravais-Pearson (linearer Zusammenhang) . . . . .	13
7.4.2	Empirische Kovarianz von X und Y . . . . .	13
7.4.3	Rangkorrelationskoeffizient nach Spearman (monotoner Zusammenhang) . . . . .	14
<b>8</b>	<b>Einfache lineare Regression</b>	<b>14</b>
8.1	Kleinste Quadrate Methode für die Regressionskoeffizienten . . . . .	14
8.2	Bestimmtheitsmaß . . . . .	14

<b>9</b>	<b>Analyse zeitlicher Verläufe</b>	<b>14</b>
9.1	Komponentenmodelle für Zeitreihen . . . . .	14
9.2	Lineares Trendmodell . . . . .	15
9.3	Einfacher gleitender Durchschnitt der Ordnung $p$ . . . . .	15
9.4	Indexzahlen . . . . .	16
9.4.1	Umsatzindex . . . . .	16
9.4.2	Preisindex nach Laspeyres . . . . .	16
9.4.3	Preisindex nach Paasche . . . . .	16
9.4.4	Mengenindex nach Laspeyres . . . . .	16
9.4.5	Mengenindex nach Paasche . . . . .	16
9.4.6	Index von March . . . . .	16
<b>10</b>	<b>Wahrscheinlichkeitsrechnung</b>	<b>17</b>
10.1	Mengenoperationen . . . . .	17
10.2	Wahrscheinlichkeiten . . . . .	17
10.2.1	Laplace-Wahrscheinlichkeiten . . . . .	17
10.2.2	Rechenregeln für Wahrscheinlichkeiten . . . . .	17
10.2.3	Bedingte Wahrscheinlichkeit von $A$ gegeben $B$ . . . . .	17
10.2.4	Satz von der totalen Wahrscheinlichkeit . . . . .	17
10.2.5	Satz von Bayes . . . . .	18
10.2.6	Unabhängigkeit von zwei Ereignissen . . . . .	18
<b>11</b>	<b>Zufallsstichproben</b>	<b>18</b>
11.1	Allgemeines . . . . .	18
11.2	Anzahl möglicher Stichproben . . . . .	18
<b>12</b>	<b>Eindimensionale Zufallsvariablen</b>	<b>18</b>
12.1	Dichte . . . . .	18
12.2	Verteilungsfunktion . . . . .	19
12.3	Rechnen mit Verteilungsfunktion und Dichte . . . . .	19
12.4	Modus . . . . .	19
12.5	Erwartungswert . . . . .	19
12.5.1	Definition . . . . .	19
12.5.2	Transformationen . . . . .	20
12.6	Varianz und Standardabweichung . . . . .	20
12.7	Quantile . . . . .	20
<b>13</b>	<b>Mehrdimensionale Zufallsvariablen</b>	<b>21</b>
13.1	Gemeinsame Dichte und Randdichte . . . . .	21
13.2	Bedingte Dichte . . . . .	21
13.3	Unabhängigkeit von Zufallsvariablen . . . . .	21
13.4	Kovarianz . . . . .	21
13.4.1	Diskrete Zufallsvariablen . . . . .	21
13.4.2	Stetige Zufallsvariablen . . . . .	21
13.5	Rechenregeln Erwartungswert, Varianz, Kovarianz . . . . .	22
13.6	Korrelationskoeffizient . . . . .	22
<b>14</b>	<b>Diskrete Verteilungen</b>	<b>22</b>
14.1	Bernoulli-Verteilung . . . . .	22
14.2	Binomialverteilung . . . . .	22
14.3	Die hypergeometrische Verteilung . . . . .	23
14.4	Die Poisson-Verteilung . . . . .	23
<b>15</b>	<b>Stetige Verteilungen</b>	<b>23</b>
15.1	Die stetige Gleichverteilung (Rechteckverteilung) auf $[a, b]$ . . . . .	23
15.2	Die Normalverteilung . . . . .	23
15.2.1	Eigenschaften . . . . .	23
15.2.2	Bestimmung von Wahrscheinlichkeiten $P(a \leq X \leq b)$ . . . . .	24
15.2.3	Bestimmung von Quantilen . . . . .	24
15.3	t-Verteilung mit $n$ Freiheitsgraden (Student t-Verteilung) . . . . .	24

<b>16 Schätzer</b>	<b>24</b>
16.1 Schätzer für Erwartungswert und Varianz . . . . .	24
16.2 Konfidenzintervalle für $\mu$ im Normalverteilungsmodell . . . . .	25
16.3 Approximative Konfidenzintervalle für $\mu$ . . . . .	25
<b>17 Statistische Hypothesentests</b>	<b>25</b>
17.1 Gauß-Test . . . . .	25
17.2 t-Test . . . . .	26
17.3 Approximativer Gauß-Test . . . . .	26
17.4 Test auf einen Anteil . . . . .	26
17.5 $\chi^2$ Unabhängigkeitstest . . . . .	27

## 1 Summenzeichen

$$\begin{aligned}\sum (x_i + y_i) &= \sum x_i + \sum y_i \\ \sum_{i=1}^n c x_i &= c \sum_{i=1}^n x_i \\ \sum_{i=1}^n c &= n \cdot c\end{aligned}$$

## 2 Häufigkeitsverteilungen

### 2.1 Absolute Häufigkeit

$h_j = h(a_j)$  = Anzahl der Fälle in denen Ausprägung  $a_j$  auftritt

$a_j$  = j-te Merkmalsausprägung

mit  $j = 1, \dots, k$

$$\text{Es gilt: } \sum_{j=1}^k h_j = n$$

### 2.2 Relative Häufigkeit

$$f_j = f(a_j) = \frac{h(a_j)}{n} \quad \text{Es gilt: } \sum_{j=1}^k f_j = 1$$

### 2.3 Histogramm

Klasseneinteilung: bei n Beobachtungen  $\approx \sqrt{n}$

Klassenbreite ( $d_j$ ) = obere Klassengrenze - untere Klassengrenze =  $x_j^0 - x_j^u$

$$f_j^r = \text{Höhe} = \frac{f_j}{d_j}$$

### 2.4 Empirische Verteilungsfunktion

Für unklassierte Häufigkeitsverteilung (Urliste muss in Häufigkeitsverteilung überführt werden)

$$F(x) = \sum_{j: a_j \leq x} f(a_j) = \sum_{j: a_j \leq x} f_j \quad (\text{kumulierte relative Häufigkeit})$$

Für klassierte Häufigkeitsverteilung

$$F(x) = \begin{cases} 0 & , x < x_1^u \\ \text{kum} f_{j-1} + \frac{x - x_j^u}{d_j} \cdot f_j & , x_1^u \leq x < x_k^o \\ 1 & , x_k^o \leq x \end{cases}$$

## 3 Lagemaße

### 3.1 Lagemaße I: Daten als Urliste

#### 3.1.1 Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{für Urliste})$$

Bei linearer Transformation:  $x_i \mapsto y_i = a \cdot x_i + b \Rightarrow \bar{y} = a \cdot \bar{x} + b$

$$\bar{x} = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j \quad \left( \text{wobei } n = \sum_{j=1}^r n_j \right), \text{ Mittelwert aus Teilgesamtheiten (r Schichten)}$$

### 3.1.2 Geometrisches Mittel

Beobachtete Reihe des Merkmals  $X$  (Zeitreihe):  $x_0, x_1, \dots, x_n$

$$r_t = \frac{x_t - x_{t-1}}{x_{t-1}} \quad (\text{Wachstumsrate})$$

$$w_t = 1 + r_t = \frac{x_t}{x_{t-1}} \quad (\text{Wachstumsfaktor})$$

- durchschnittlicher Wachstumsfaktor  $\bar{w}_{geom}$

$$x_n = x_0 \cdot \bar{w}_{geom}^n$$

$$\bar{w}_{geom} = \sqrt[n]{\prod_{t=1}^n w_t} = \sqrt[n]{w_1 \cdot w_2 \cdot \dots \cdot w_n}$$

$$\bar{w}_{geom} = \sqrt[n]{\frac{x_n}{x_0}} = \sqrt[n]{(1 + r_1) \cdot (1 + r_2) \cdot \dots \cdot (1 + r_n)}$$

- durchschnittliche Wachstumsrate  $\bar{r}_{geom}$

$$\bar{r}_{geom} = \bar{w}_{geom} - 1$$

### 3.1.3 Median (Zentralwert)

Ordnungsstatistiken  $x_{(1)} \leq \dots \leq x_{(n)}$

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & , \text{ falls } n \text{ ungerade} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & , \text{ falls } n \text{ gerade} \end{cases}$$

### 3.1.4 Modus (Modalwert)

Ausprägung mit größter relativer Häufigkeit.

Nicht bestimmbar, wenn mehrere Ausprägungen größte relative Häufigkeit besitzen.

**Modalitätsgrad:** relative Häufigkeit des Modus in Prozent =  $f_{mod} \cdot 100\%$

### 3.1.5 p-Quantile ( $0 < p < 1$ )

$$x_p = \begin{cases} x_{([n \cdot p] + 1)} & , \text{ wenn } n \cdot p \text{ nicht ganzzahlig, wobei } [n \cdot p] \text{ die} \\ & \text{zu } n \cdot p \text{ nächst kleinere ganze Zahl} \\ \frac{1}{2}(x_{(n \cdot p)} + x_{(n \cdot p + 1)}) & , \text{ wenn } n \cdot p \text{ ganzzahlig} \end{cases}$$

#### Fünf-Punkte-Zusammenfassung:

Teilt den Wertebereich in 4 Intervalle die jeweils ca. ein Viertel der Werte enthalten.

$x_{(1)}$	...	kleinster Wert
$x_{0.25}$	...	unteres Quartil
$x_{med}$	...	Median
$x_{0.75}$	...	oberes Quartil
$x_{(n)}$	...	größter Wert

Arithmetisches Mittel

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	$\bar{x} = \frac{1}{n} \sum_{j=1}^k a_j \cdot h(a_j) = \sum_{j=1}^k a_j \cdot f(a_j)$	Nutze Klassenmitten $m_j = \frac{x_j^o + x_j^u}{2}$ $\bar{x} = \frac{1}{n} \sum_{j=1}^k m_j \cdot n_j = \sum_{j=1}^k m_j \cdot f_j$ (Näherung)

p-Quantil

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
$x_p = \begin{cases} x_{([np]+1)} & , np \text{ nicht ganzzahl.} \\ \frac{1}{2}(x_{(np)} + x_{(np+1)}) & , np \text{ ganzzahlig} \end{cases}$	(1) Suche nach der Ausprägung $a_j$ , bei der $kumf_j = p$ erstmals überschritten oder genau erreicht wird (2a) Wird p bei $a_j$ überschritten: $x_p = a_j$ (2b) Wird p genau bei $a_j$ erreicht: $x_p = \frac{a_j + a_{j+1}}{2}$	(1) Bestimme Klasse, in der $kumf_j = p$ erstmals überschritten wird (2) $x_p = x_j^u + (p - kumf_{j-1}) \cdot \frac{d_j}{f_j}$

Median

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
Nutze Rechenvorschriften für p-Quantile mit p=0.5		

Modus

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
Die Merkmalsausprägung $a_j$ mit der größten Häufigkeit $h(a_j)$ bildet den Modus		(1) Modalklasse: Klasse $j$ mit größter Besetzungsdichte $f_j^r = f_j/d_j$ (2) Näherung für Modus: $x_{mod} = \frac{x_j^o + x_j^u}{2}$

## 4 Streuungsmaße

### 4.1 Spannweite (Range)

$$R = x_{(n)} - x_{(1)}$$

### 4.2 Interquartilsabstand

$$d_Q = x_{0.75} - x_{0.25}$$

### 4.3 Mediane absolute Abweichung vom Median (MAD)

$$MAD = med \{ |x_i - x_{med}|, i = 1, \dots, n \}$$

### 4.4 Empirische Varianz I: Daten als Urliste

$$\tilde{s}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \left( \frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \quad (\text{Verschiebungssatz})$$

$$\tilde{s}^2 = \frac{1}{n} \left( \sum_{j=1}^r n_j \cdot \tilde{s}_j^2 + \sum_{j=1}^r n_j \cdot (\bar{x}_j - \bar{x})^2 \right), \text{Varianz aus Teilgesamtheiten (r Schichten)}$$

Bei linearer Transformation:  $x_i \mapsto y_i = a \cdot x_i + b \Rightarrow \tilde{s}_y^2 = a^2 \cdot \tilde{s}_x^2$

Ist X normalverteilt (großes n) gilt:

$\bar{x} \pm \tilde{s} \rightarrow \text{ca. 68\% aller Beobachtungen}$   
 $\bar{x} \pm 2 \cdot \tilde{s} \rightarrow \text{ca. 95\% aller Beobachtungen}$   
 $\bar{x} \pm 3 \cdot \tilde{s} \rightarrow \text{ca. 99\% aller Beobachtungen}$



### Varianz

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
$\tilde{s}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$	$\begin{aligned} \tilde{s}^2 &= \frac{1}{n} \sum_{j=1}^k (a_j - \bar{x})^2 \cdot h(a_j) \\ &= \sum_{j=1}^k (a_j - \bar{x})^2 \cdot f(a_j) \end{aligned}$	$\tilde{s}^2 = \tilde{s}_{ext}^2 + \tilde{s}_{int}^2$ <p>Einzelwerte <math>x_{ij}</math> in den Klassen unbekannt;  Klassenmittelwerte <math>\bar{x}_j</math> können nicht berechnet werden;  Verwende daher die Klassenmitten <math>m_j = \frac{x_j^o + x_j^u}{2}</math>  (a) Es liegen Informationen über Klassenvarianzen <math>\tilde{s}_j^2</math> vor:  <math display="block">\begin{aligned} \tilde{s}^2 &amp;= \frac{1}{n} \sum_{j=1}^k (m_j - \bar{x})^2 \cdot n_j + \frac{1}{n} \sum_{j=1}^k \tilde{s}_j^2 \cdot n_j \\ &amp;= \sum_{j=1}^k (m_j - \bar{x})^2 \cdot f_j + \sum_{j=1}^k \tilde{s}_j^2 \cdot f_j \end{aligned}</math>  (b) Keine Informationen über <math>\tilde{s}_j^2</math>; Setze <math>\tilde{s}_j^2 = 0</math>:  <math display="block">\tilde{s}^2 = \frac{1}{n} \sum_{j=1}^k (m_j - \bar{x})^2 \cdot n_j = \sum_{j=1}^k (m_j - \bar{x})^2 \cdot f_j</math></p>

9

### Verschiebungssatz der Varianz

Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung
$\tilde{s}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$	$\begin{aligned} \tilde{s}^2 &= \frac{1}{n} \sum_{j=1}^k a_j^2 \cdot h(a_j) - \bar{x}^2 \\ &= \sum_{j=1}^k a_j^2 \cdot f(a_j) - \bar{x}^2 \end{aligned}$	<p>(a) Es liegen Informationen über Klassenvarianzen <math>\tilde{s}_j^2</math> vor:  <math display="block">\begin{aligned} \tilde{s}^2 &amp;= \frac{1}{n} \sum_{j=1}^k m_j^2 \cdot n_j - \bar{x}^2 + \frac{1}{n} \sum_{j=1}^k \tilde{s}_j^2 \cdot n_j \\ &amp;= \sum_{j=1}^k m_j^2 \cdot f_j - \bar{x}^2 + \sum_{j=1}^k \tilde{s}_j^2 \cdot f_j \end{aligned}</math>  (b) Keine Informationen über <math>\tilde{s}_j^2</math>; Setze <math>\tilde{s}_j^2 = 0</math>:  <math display="block">\tilde{s}^2 = \frac{1}{n} \sum_{j=1}^k m_j^2 \cdot n_j - \bar{x}^2 = \sum_{j=1}^k m_j^2 \cdot f_j - \bar{x}^2</math></p>

## 4.6 Stichprobenvarianz

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left( \sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2 \right) \quad (\text{Verschiebungssatz})$$

## 4.7 Standardabweichung

$$\tilde{s} = \sqrt{\tilde{s}^2}$$

## 4.8 Standardisierung

$$x_i \mapsto z_i = \frac{x_i - \bar{x}}{\tilde{s}_x} = \underbrace{\frac{1}{\tilde{s}_x}}_a \cdot x_i - \underbrace{\frac{1}{\tilde{s}_x} \cdot \bar{x}}_b$$

Es gilt:  $\bar{z} = 0$  und  $\tilde{s}_z^2 = 1$

## 4.9 Variationskoeffizient

$$v = \frac{\tilde{s}}{\bar{x}}$$

# 5 Schiefemaße

## 5.1 Lageregeln

- $x_{mod} < x_{med} < \bar{x} \rightarrow$  rechtsschief
- $x_{mod} = x_{med} = \bar{x} \rightarrow$  symmetrisch
- $\bar{x} < x_{med} < x_{mod} \rightarrow$  linksschief

## 5.2 Schiefekoeffizient nach Pearson (Momentenkoeffizient)

$$g_m = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\sqrt{\left( \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^3}}$$

- $g_m > 0 \rightarrow$  rechtsschief
- $g_m = 0 \rightarrow$  symmetrisch
- $g_m < 0 \rightarrow$  linksschief

# 6 Konzentrationsmaße

## 6.1 Relative Konzentration

### 6.1.1 Gini-Koeffizient

Wertebereich:  $0 \leq G \leq \frac{n-1}{n}$

**Normierter Gini-Koeffizient**

Wertebereich:  $0 \leq G^* \leq 1$

$$G^* = \frac{n}{n-1} G$$

### Relative Konzentration

	Urliste	unklassierte Häufigkeitsverteilung	klassierte Häufigkeitsverteilung (Merkmalssummen unbekannt)	klassierte Häufigkeitsverteilung (Merkmalssummen bekannt)
Gini-Koeffizient	$G = \sum_{i=1}^n u_i \cdot \tilde{v}_i + \sum_{i=1}^n u_{i-1} \cdot \tilde{v}_i - 1$	$G = \sum_{j=1}^k u_j \cdot \tilde{v}_j + \sum_{j=1}^k u_{j-1} \cdot \tilde{v}_j - 1$		
q	$\in 1, 2, \dots, n$	$\in 1, 2, \dots, k$		
relative Häufigkeit	$f_q = \frac{n_q}{n} = \frac{1}{n}$	$f(a_q) = \frac{h(a_q)}{n} = \frac{h(a_q)}{\sum_{j=1}^k h(a_j)}$	$f_q = \frac{n_q}{n} = \frac{n_q}{\sum_{j=1}^k n_j}$	$f_q = \frac{n_q}{n} = \frac{n_q}{\sum_{j=1}^k n_j}$
kumulierte rel. Häufigkeit	$u_q = \sum_{i=1}^q f_i = \frac{q}{n}$	$u_q = \sum_{j=1}^q f(a_j)$	$u_q = \sum_{j=1}^q f_j$	$u_q = \sum_{j=1}^q f_j$
relativer Merkmalsanteil	$\tilde{v}_q = \frac{x_{(q)}}{\sum_{i=1}^n x_i}$	$\tilde{v}_q = \frac{a_q \cdot h(a_q)}{\sum_{j=1}^k a_j \cdot h(a_j)} = \frac{a_q \cdot f(a_q)}{\sum_{j=1}^k a_j \cdot f(a_j)}$	$\tilde{v}_q = \frac{m_q \cdot n_q}{\sum_{j=1}^k m_j \cdot n_j} = \frac{m_q \cdot f_q}{\sum_{j=1}^k m_j \cdot f_j}$	$\tilde{v}_q = \frac{x_q}{\sum_{j=1}^k x_j}$
kumulierter rel. Merkmalsanteil	$v_q = \sum_{i=1}^q \tilde{v}_i$	$v_q = \sum_{j=1}^q \tilde{v}_j$	$v_q = \sum_{j=1}^q \tilde{v}_j$	$v_q = \sum_{j=1}^q \tilde{v}_j$

### 6.1.2 Lorenzkurve

Streckenzug durch

$$(0, 0) = (u_0, v_0), (u_1, v_1), \dots, (u_n, v_n) = (1, 1) \quad (\text{Urliste})$$

bzw.

$$(0, 0) = (u_0, v_0), (u_1, v_1), \dots, (u_k, v_k) = (1, 1) \quad (\text{unklassierte oder klassierte Hufigkeitsverteilung})$$

## 6.2 Absolute Konzentration

Index nach Hirschmann/Herfindahl. Beschreibt die absolute Konzentration.

Es muss gelten:  $\sum_{i=1}^n x_i > 0$ . Wertebereich:  $\frac{1}{n} \leq H \leq 1$

$$H = \sum_{i=1}^n \tilde{v}_i^2 \quad (\text{Urliste})$$

$$H = \frac{V^2+1}{n} \text{ mit } V = \frac{\tilde{s}}{\bar{x}} \quad (\text{unklassierte Hufigkeitsverteilung})$$

$$H = \frac{V^2+1}{n} \text{ mit } V = \frac{\tilde{s}}{\bar{x}} \quad (\text{klassierte Hufigkeitsverteilung})$$

## 7 Mehrdimensionale Merkmale

### 7.1 Kontingenztafeln

(k x m)-Kontingenztafel

$a_i$  - Zeilen  $i = 1, \dots, k$

$b_j$  - Spalten  $j = 1, \dots, m$

$$h_{ij} = h(a_i, b_j) \quad \dots \text{ absolute Hufigkeit der Kombination } (a_i, b_j)$$

$$f_{ij} = f(a_i, b_j) = \frac{h_{ij}}{n} \quad \dots \text{ relative Hufigkeit der Kombination } (a_i, b_j)$$

$$f_{i\bullet} = \sum_{j=1}^m f_{ij} = \frac{h_{i\bullet}}{n}, i = 1, \dots, k \quad \dots \text{ relative Randhufigkeiten von X}$$

$$f_{\bullet j} = \sum_{i=1}^k f_{ij} = \frac{h_{\bullet j}}{n}, j = 1, \dots, m \quad \dots \text{ relative Randhufigkeiten von Y}$$

### 7.2 Bedingte Verteilungen

#### 7.2.1 Bedingte Verteilung von X

$$f_X(a_i|b_j) = \frac{f_{ij}}{f_{\bullet j}} = \frac{h_{ij}}{h_{\bullet j}}$$

$f_X(a_1|b_j), \dots, f_X(a_k|b_j)$  heit bedingte Verteilung von X geg.  $Y = b_j$

Es gilt:  $\sum_{i=1}^k f_X(a_i|b_j) = 1$  fur jedes feste j,  $j = 1, \dots, m$

#### 7.2.2 Bedingte Verteilung von Y

$$f_Y(b_j|a_i) = \frac{f_{ij}}{f_{i\bullet}} = \frac{h_{ij}}{h_{i\bullet}}$$

$f_Y(b_1|a_i), \dots, f_Y(b_m|a_i)$  heit bedingte Verteilung von Y geg.  $X = a_i$

Es gilt:  $\sum_{j=1}^m f_Y(b_j|a_i) = 1$  fur jedes feste i,  $i = 1, \dots, k$

### 7.2.3 Rekonstruktion der gemeinsamen Häufigkeiten

$$f_{ij} = f_Y(b_j|a_i) \cdot f_{i\bullet} \quad \text{bzw.} \quad f_{ij} = f_X(a_i|b_j) \cdot f_{\bullet j}$$

## 7.3 Zusammenhangsanalyse in Kontingenztafeln

### 7.3.1 Hypothetische absolute Häufigkeit (bei Unabhängigkeit der Merkmale)

$$e_{ij} = \frac{h_{i\bullet} \cdot h_{\bullet j}}{n}$$

### 7.3.2 Chi-Quadrat Koeffizient

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - e_{ij})^2}{e_{ij}} \quad , \quad \chi^2 \in [0, \infty)$$

### 7.3.3 Kontingenzkoeffizient

$$K = \sqrt{\frac{\chi^2}{n + \chi^2}} \quad , \quad K \in \left[0, \sqrt{\frac{M-1}{M}}\right], \text{ wobei } M = \min\{k, m\}$$

### 7.3.4 Korrigierter Kontingenzkoeffizient

$$K^* = \frac{K}{\sqrt{\frac{M-1}{M}}} \quad , \quad K^* \in [0, 1]$$

$K^* \leq 0.2$	$\rightarrow$ kein wesentlicher Zusammenhang
$0.2 < K^* \leq 0.5$	$\rightarrow$ schwacher Zusammenhang
$0.5 < K^* < 0.8$	$\rightarrow$ deutlicher Zusammenhang
$0.8 \leq K^*$	$\rightarrow$ starker Zusammenhang

## 7.4 Zusammenhangsmaße bei metrischen Merkmalen

### 7.4.1 Korrelationskoeffizient nach Bravais-Pearson (linearer Zusammenhang)

Wertebereich:  $-1 \leq r_{XY} \leq 1$

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\tilde{s}_X \cdot \tilde{s}_Y}$$

$$\text{alternativ: } r_{XY} = \frac{\sum_{i=1}^n x_i \cdot y_i - n \cdot \bar{x} \cdot \bar{y}}{\sqrt{\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2} \cdot \sqrt{\sum_{i=1}^n y_i^2 - n \cdot \bar{y}^2}} = \frac{\frac{1}{n} \sum_{i=1}^n x_i \cdot y_i - \bar{x} \cdot \bar{y}}{\sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2} \cdot \sqrt{\frac{1}{n} \sum_{i=1}^n y_i^2 - \bar{y}^2}}$$

Stärke des linearen Zusammenhangs: Betrachte  $|r_{XY}|$ , Einteilung wie in 7.3.4

### 7.4.2 Empirische Kovarianz von X und Y

Wertebereich:  $-\infty \leq \tilde{s}_{XY} \leq \infty$

$$\tilde{s}_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) = \frac{1}{n} \cdot \sum_{i=1}^n x_i \cdot y_i - \bar{x} \cdot \bar{y}$$

### 7.4.3 Rangkorrelationskoeffizient nach Spearman (monotoner Zusammenhang)

Wertebereich:  $-1 \leq r_{Sp} \leq 1$

Basiert auf den Rängen der beobachteten Werte.

1. Allgemein

$$r_{Sp} = \frac{\sum_{i=1}^n (rg(x_i) - \frac{n+1}{2}) \cdot (rg(y_i) - \frac{n+1}{2})}{\sqrt{\left(\sum_{i=1}^n (rg(x_i))^2 - \frac{n \cdot (n+1)^2}{4}\right) \cdot \left(\sum_{i=1}^n (rg(y_i))^2 - \frac{n \cdot (n+1)^2}{4}\right)}}$$

$$= \frac{\sum_{i=1}^n rg(x_i) \cdot rg(y_i) - \frac{n \cdot (n+1)^2}{4}}{\sqrt{\left(\sum_{i=1}^n (rg(x_i))^2 - \frac{n \cdot (n+1)^2}{4}\right) \cdot \left(\sum_{i=1}^n (rg(y_i))^2 - \frac{n \cdot (n+1)^2}{4}\right)}}$$

2. Ohne Bindungen

$$r_{Sp} = 1 - \frac{6 \cdot \sum_{i=1}^n d_i^2}{n \cdot (n^2 - 1)}, \text{ wobei } d_i = rg(x_i) - rg(y_i)$$

Stärke des monotonen Zusammenhangs: Betrachte  $|r_{Sp}|$ , Einteilung wie in 7.3.4

## 8 Einfache lineare Regression

Sei  $Y$  eine interessierende Zielgröße mit den Beobachtungen  $y$  und  $x$  eine deterministische Einflussgröße. Modell:

$$y = a \cdot x + b + \varepsilon$$

### 8.1 Kleinste Quadrate Methode für die Regressionskoeffizienten

$$\hat{a} = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i \cdot y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2}$$

$$\hat{b} = \bar{y} - \hat{a} \cdot \bar{x}$$

Die Werte  $\hat{y}_i = \hat{a} \cdot x_i + \hat{b}$  sind Vorhersagen oder Prognosen für die  $y_i$ .  
Die Abweichungen  $\hat{\varepsilon}_i = y_i - \hat{y}_i$  heißen **Residuen**.

### 8.2 Bestimmtheitsmaß

Güte der Anpassung der Daten an die berechnete Gerade.

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad R^2 \in [0, 1]$$

Es gilt:  $R^2 = r_{XY}^2$  (quadrierter Korrelationskoeffizient)

## 9 Analyse zeitlicher Verläufe

### 9.1 Komponentenmodelle für Zeitreihen

Trendkomponente ( $g$ ) : langfristiges Verhalten

Saisonkomponente ( $s$ ) : wiederkehrende zyklische Schwankungen

Irreguläre Komponente ( $\varepsilon$ ) : Rest

1. Additives Modell:

$$y_t = g_t + s_t + \varepsilon_t, \quad t = 1, \dots, T$$

2. Multiplikatives Modell:

$$y_t = g_t \cdot s_t \cdot \varepsilon_t, \quad t = 1, \dots, T$$

Rückführung auf Additives Modell mit  $\log(y_t) = \log(g_t) + \log(s_t) + \log(\varepsilon_t)$  möglich.

## 9.2 Lineares Trendmodell

- Reines Trendmodell:

$$y_t = g_t + \varepsilon_t$$

- Trendmodell mit im zeitlichem Verlauf linearer Trendkomponente:

$$y_t = \alpha \cdot t + \beta + \varepsilon_t, \quad t = 1, \dots, T \quad (\text{Bestimmung mit KQ-Methode})$$

## 9.3 Einfacher gleitender Durchschnitt der Ordnung p

Betrachtet wird eine Zeitreihe  $y_1, \dots, y_T$ .

Ordnung p des gleitenden Durchschnitts gibt die Anzahl der in die Mittelwertberechnung eingehenden Zeitreihenwerte an. Trend  $g_t$  durch ein lokales arithmetisches Mittel der Zeitreihenwerte  $y_{t-q}, \dots, y_{t+q}$  approximieren:

- für ungerade Ordnung p:  $q = \frac{p-1}{2}$

$$\hat{g}_t^p = \frac{1}{2 \cdot q + 1} \sum_{j=-q}^q y_{t+j} = \frac{1}{p} \cdot (y_{t-q} + \dots + y_t + \dots + y_{t+q})$$

mit  $t = q + 1, \dots, T - q$

- für gerade Ordnungp:  $q = \frac{p}{2}$

$$\hat{g}_t^p = \frac{1}{p} \left( \frac{1}{2} \cdot y_{t-q} + \sum_{j=-q+1}^{q-1} y_{t+j} + \frac{1}{2} \cdot y_{t+q} \right)$$

mit  $t = q + 1, \dots, T - q$

## 9.4 Indexzahlen

Bezeichnung: Basiszeit 0	mit Preisen	$p_0(1), \dots, p_0(n)$
	und Gütermengen	$q_0(1), \dots, q_0(n)$
Berichtszeit $t$	mit Preisen	$p_t(1), \dots, p_t(n)$
	und Gütermengen	$q_t(1), \dots, q_t(n)$

### 9.4.1 Umsatzindex

$$W_{0,t} = \frac{\sum_{i=1}^n p_t(i) \cdot q_t(i)}{\sum_{i=1}^n p_0(i) \cdot q_0(i)} \cdot 100$$

### 9.4.2 Preisindex nach Laspeyres

$$P_{0,t}^L = \frac{\sum_{i=1}^n p_t(i) \cdot q_0(i)}{\sum_{i=1}^n p_0(i) \cdot q_0(i)} \cdot 100$$

### 9.4.3 Preisindex nach Paasche

$$P_{0,t}^P = \frac{\sum_{i=1}^n p_t(i) \cdot q_t(i)}{\sum_{i=1}^n p_0(i) \cdot q_t(i)} \cdot 100$$

### 9.4.4 Mengenindex nach Laspeyres

$$Q_{0,t}^L = \frac{\sum_{i=1}^n q_t(i) \cdot p_0(i)}{\sum_{i=1}^n q_0(i) \cdot p_0(i)} \cdot 100$$

### 9.4.5 Mengenindex nach Paasche

$$Q_{0,t}^P = \frac{\sum_{i=1}^n q_t(i) \cdot p_t(i)}{\sum_{i=1}^n q_0(i) \cdot p_t(i)} \cdot 100$$

### 9.4.6 Index von March

$$I_M = \frac{\sum_{i=1}^n \frac{p_t(i)}{p_0(i)} \cdot q_t(i)}{\sum_{i=1}^n q_t(i)}$$



## 10 Wahrscheinlichkeitsrechnung

### 10.1 Mengenoperationen

Seien A und B Teilmengen einer Menge  $\Omega$

- **Schnittmenge:**  $A \cap B$
- **Vereinigungsmenge:**  $A \cup B$
- **Differenzmenge:**  $A \setminus B$
- **Komplementärmenge oder Komplement:**  $A^C$
- **Anzahl der Elemente von A:**  $|A|$

### 10.2 Wahrscheinlichkeiten

#### 10.2.1 Laplace-Wahrscheinlichkeiten

$P(A)$  ... Wahrscheinlichkeit des Ereignisses A

Gilt für  $\Omega = \{\omega_1, \dots, \omega_n\}$ , dass  $P(\{\omega_i\}) = \frac{1}{n}$ ,  $i = 1, \dots, n$

dann gilt für  $A \subseteq \Omega$ , zusammengesetzt aus m Elementarereignissen:

$$P(A) = \frac{m}{n} = \frac{\text{Anzahl der Elementarereignisse in A}}{\text{Gesamtzahl der Elementarereignisse}}$$

#### 10.2.2 Rechenregeln für Wahrscheinlichkeiten

Für eine Wahrscheinlichkeitsabbildung P und Ereignisse  $A, B, A_1, \dots, A_k$  sowie eine Grundmenge  $\Omega$  von Ergebnissen gilt:

- $0 \leq P(A) \leq 1$
- $P(\emptyset) = 0$
- Falls  $A \subseteq B \Rightarrow P(A) \leq P(B)$
- $P(A^C) = 1 - P(A)$
- Sind  $A_1, \dots, A_k$  paarweise disjunkt, dann gilt:

$$P(A_1 \cup \dots \cup A_k) = P(A_1) + \dots + P(A_k)$$

- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- Ist  $\Omega$  endlich mit Elementarereignissen  $\{\omega_1\}, \dots, \{\omega_n\}$ , dann ist  $P(A) = \sum_{\omega \in A} P(\{\omega\})$

#### 10.2.3 Bedingte Wahrscheinlichkeit von A gegeben B

Seien  $A, B \subset \Omega$  und  $P(B) > 0$ .

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A \cap B) = P(A|B) \cdot P(B) \quad (\text{Produktsatz})$$

#### 10.2.4 Satz von der totalen Wahrscheinlichkeit

Sei  $B_1, \dots, B_k$  eine disjunkte Zerlegung von  $\Omega$ .

Dann gilt für  $A \subset \Omega$ :

$$P(A) = \sum_{i=1}^k P(A|B_i) \cdot P(B_i)$$

### 10.2.5 Satz von Bayes

Sei  $B_1, \dots, B_k$  eine disjunkte Zerlegung von  $\Omega$ , wobei  $P(B_i) > 0$  und  $P(A|B_i) > 0$  für mindestens ein  $i$ .

Dann gilt:

$$P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^k P(A|B_j) \cdot P(B_j)} = \frac{P(A|B_i) \cdot P(B_i)}{P(A)}, \quad i = 1, \dots, k$$

### 10.2.6 Unabhängigkeit von zwei Ereignissen

Seien  $A, B \subset \Omega$  zwei Ereignisse.

A und B heißen (stochastisch) unabhängig, wenn gilt:

$$P(A \cap B) = P(A) \cdot P(B)$$

Alternativ:  $P(A|B) = P(A)$  mit  $P(B) > 0$  oder  $P(B|A) = P(B)$  mit  $P(A) > 0$   
Falls  $P(B) = 0$ , so nennt man A und B stets unabhängig.

## 11 Zufallsstichproben

### 11.1 Allgemeines

Umfang Grundgesamtheit ...  $N$

Umfang Stichprobe ...  $n$

**Einfache Zufallsstichprobe**

Jede mögliche Stichprobe vom Umfang  $n$  aus der Grundgesamtheit hat die selbe Wahrscheinlichkeit realisiert zu werden.

### 11.2 Anzahl möglicher Stichproben

	ohne Zurücklegen	mit Zurücklegen
mit Beachtung der Reihenfolge	$\frac{N!}{(N-n)!}$	$N^n$
ohne Beachtung der Reihenfolge	$\binom{N}{n}$	$\binom{N+n-1}{n}$

## 12 Eindimensionale Zufallsvariablen

### 12.1 Dichte

1. **Diskrete Dichte** (f(x) Wahrscheinlichkeitsfunktion!)

$$f(x_i) = P(X = x_i)$$

Es gilt:  $\forall i : 0 \leq f(x_i) \leq 1$  und  $\sum_{i=1}^{\infty} f(x_i) = 1$ .

2. **Stetige Dichte** (f(x) Dichtefunktion!)

$$f(x) = F'(x), \text{ falls die Ableitung existiert}$$

Es gilt:  $\forall x : f(x) \geq 0$  und  $\int_{-\infty}^{\infty} f(t)dt = 1$ . ( $f(x) \geq 1$  ist möglich!)

## 12.2 Verteilungsfunktion

$$F(x) = P(X \leq x)$$

### 1. Diskreter Wertebereich

$$F(x) = \sum_{x_i \leq x} f(x_i)$$

### 2. Stetiger Wertebereich

$$F(x) = \int_{-\infty}^x f(t) dt$$

## 12.3 Rechnen mit Verteilungsfunktion und Dichte

### 1. Diskrete Zufallsvariable $X$

- $P(a < X \leq b) = \sum_{x_i: a < x_i \leq b} P(X = x_i)$
- Alternativ mit Hilfe der Verteilungsfunktion:  
 $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$
- $P(a \leq X \leq b) = F(b) - P(X < a)$
- $P(a \leq X < b) = P(X < b) - P(X < a)$
- $P(a < X < b) = P(X < b) - P(X \leq a) = P(X < b) - F(a)$
- $P(X > a) = 1 - F(a)$

### 2. Stetige Zufallsvariable $X$

- $P(a < X \leq b) = \int_a^b f(t) dt$
- Alternativ mit Hilfe der Verteilungsfunktion:  
 $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$
- $P(X = x) = 0$  für jedes  $x$ , d.h. Wahrscheinlichkeit einen bestimmten Wert anzunehmen ist gleich Null.
- $P(a < X < b) = P(a < X \leq b) = P(a \leq X \leq b) = P(a \leq X < b)$
- $P(X > a) = P(X \geq a) = 1 - F(a)$

## 12.4 Modus

Modus der Verteilung von  $X$  ist derjenige  $x$ -Wert  $x_{mod}$ , für den die Dichte  $f(x)$  von  $X$  maximal wird.

Gibt es keinen eindeutigen  $x$ -Wert der dies erfüllt, so ist der Modus nicht definiert.

## 12.5 Erwartungswert

### 12.5.1 Definition

Betrachtet wird eine Zufallsvariable  $X$  mit Dichtefunktion  $f(x)$ .

#### 1. Ist $X$ diskrete Zufallsvariable:

$$E(X) = \sum_{i=1}^{\infty} x_i \cdot f(x_i) = x_1 \cdot f(x_1) + x_2 \cdot f(x_2) + \dots$$

2. Ist  $X$  **stetige Zufallsvariable**:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

### 12.5.2 Transformationen

1. **Lineare Transformation**

$$Y = a \cdot X + b \quad \rightarrow \quad E(Y) = E(a \cdot X + b) = a \cdot E(X) + b$$

2. **Transformation mit beliebiger Funktion**

$$Y = g(X)$$

- $X$  ist **diskrete** Zufallsvariable

$$E(Y) = E(g(X)) = \sum_{i=1}^{\infty} g(x_i) \cdot f(x_i)$$

- $X$  ist **stetige** Zufallsvariable

$$E(Y) = E(g(X)) = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

## 12.6 Varianz und Standardabweichung

Sei  $X$  eine Zufallsvariable mit Dichtefunktion  $f$  und Erwartungswert  $E(X)$ :

- **Varianz**

1. Ist  $X$  **diskret**:

$$\begin{aligned} Var(X) &= E((X - E(X))^2) = \sum_{i=1}^{\infty} (x_i - E(X))^2 \cdot f(x_i) \\ &= \sum_{i=1}^{\infty} x_i^2 \cdot f(x_i) - (E(X))^2 \quad (\text{Verschiebungssatz}) \end{aligned}$$

2. Ist  $X$  **stetig**:

$$\begin{aligned} Var(X) &= E((X - E(X))^2) = \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f(x) dx \\ &= \int_{-\infty}^{\infty} x^2 \cdot f(x) dx - (E(X))^2 \quad (\text{Verschiebungssatz}) \end{aligned}$$

- **Standardabweichung**  $\sigma_X = \sqrt{Var(X)}$

- **Verschiebungssatz allgemein**  $Var(X) = E(X^2) - (E(X))^2$

- **Lineare Transformation**

$$\begin{aligned} - Y &= a \cdot X + b \\ - Var(Y) &= Var(a \cdot X + b) = a^2 \cdot Var(X) \\ - \sigma_Y &= |a| \cdot \sigma_X \end{aligned}$$

## 12.7 Quantile

1. Ist  $X$  **diskrete Zufallsvariable**:

p-Quantil  $x_p$  ist die Zahl, für die

$$P(X < x_p) \leq p \quad \text{und} \quad P(X > x_p) \leq 1 - p$$

2. Ist  $X$  **stetige Zufallsvariable**:

$x_p$  ist die Zahl, für die

$$F(x_p) = p$$

Falls  $x_p$  nicht eindeutig bestimmbar, wähle jeweils die kleinste Zahl, die dies erfüllt.

## 13 Mehrdimensionale Zufallsvariablen

### 13.1 Gemeinsame Dichte und Randdichte

	diskrete Zufallsvariable	stetige Zufallsvariable
Gemeinsame Dichte	$f_{X,Y}(x_i, y_j) = P(X = x_i, Y = y_j)$	$f_{X,Y}(x, y)$
Randdichten	$f_X(x_i) = P(X = x_i)$	$f_X(x)$
	$f_Y(y_j) = P(Y = y_j)$	$f_Y(y)$
	$f_X(x_i) = \sum_{j=1}^{\infty} f_{X,Y}(x_i, y_j)$	$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$
	für $f_Y$ analog	

### 13.2 Bedingte Dichte

- bedingte Dichte von  $X$  gegeben  $Y$ :

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

- bedingte Dichte von  $Y$  gegeben  $X$ :

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

### 13.3 Unabhängigkeit von Zufallsvariablen

$X$  und  $Y$  sind stochastisch unabhängig, wenn gilt:

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y), \text{ für alle } x \in X(\Omega) \text{ und } y \in Y(\Omega)$$

### 13.4 Kovarianz

$$\text{Cov}(X, Y) = E((X - E(X)) \cdot (Y - E(Y)))$$

#### 13.4.1 Diskrete Zufallsvariablen

$$\text{Cov}(X, Y) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} (x_i - E(X)) \cdot (y_j - E(Y)) \cdot f_{X,Y}(x_i, y_j)$$

Zur vereinfachten Berechnung:

$$\text{Cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$

mit 
$$E(X \cdot Y) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} x_i \cdot y_j \cdot f_{X,Y}(x_i, y_j)$$

#### 13.4.2 Stetige Zufallsvariablen

$$\text{Cov}(X, Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - E(X)) \cdot (y - E(Y)) \cdot f_{X,Y}(x, y) dx dy$$

Zur vereinfachten Berechnung:

$$\text{Cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$

mit 
$$E(X \cdot Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot y \cdot f_{X,Y}(x, y) dx dy$$

### 13.5 Rechenregeln Erwartungswert, Varianz, Kovarianz

- $E(X + Y) = E(X) + E(Y)$
- $E(X - Y) = E(X) - E(Y)$
- $E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i)$
- $Var(X + Y) = Var(X) + Var(Y) + 2 \cdot Cov(X, Y)$
- $Var(X - Y) = Var(X) + Var(Y) - 2 \cdot Cov(X, Y)$
- $Var\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n Var(X_i)$ , falls  $X_1, \dots, X_n$  unabhängig
- $Cov(aX + b, cY + d) = a \cdot c \cdot Cov(X, Y)$

### 13.6 Korrelationskoeffizient

Wertebereich:  $-1 \leq \rho(x, y) \leq 1$

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X) \cdot Var(Y)}}$$

## 14 Diskrete Verteilungen

### 14.1 Bernoulli-Verteilung

Dichtefunktion:  $f(x_i) = p^{x_i} \cdot (1 - p)^{1-x_i}$  für  $x_i = 0, 1$

Schreibweise:  $X \sim Bin(1, p)$

Erwartungswert:  $E(X) = p$

Varianz:  $Var(X) = p \cdot (1 - p)$

### 14.2 Binomialverteilung

Dichtefunktion:  $f(x_i) = \binom{n}{x_i} \cdot p^{x_i} \cdot (1 - p)^{n-x_i}$  für  $x_i = 0, \dots, n$

Schreibweise:  $X \sim Bin(n, p)$

Erwartungswert:  $E(X) = n \cdot p$

Varianz:  $Var(X) = n \cdot p \cdot (1 - p)$

### Eigenschaften

- Beschreibt Situation des Ziehens mit Zurücklegen.
- Die Bernoulli-Verteilung ist ein Spezialfall der Binomialverteilung mit  $n = 1$ .
- Sind  $X_1, \dots, X_n$  stochastisch unabhängig mit  $X \sim Bin(1, p)$ ,  $i = 1, \dots, n$ , dann ist  $X = \sum_{i=1}^n X_i \sim Bin(n, p)$ .
- Symmetrie: Sei  $X \sim Bin(n, p)$  und  $Y = n - X$ , dann gilt:  $Y \sim Bin(n, 1 - p)$ .

### 14.3 Die hypergeometrische Verteilung

$$\text{Dichtefunktion: } f(x_i) = \frac{\binom{M}{x_i} \cdot \binom{N-M}{n-x_i}}{\binom{N}{n}} \quad \text{für } x_i = 0, \dots, n$$

$$\text{Schreibweise: } X \sim \text{Hyp}(n, M, N)$$

$$\text{Erwartungswert: } E(X) = n \cdot \frac{M}{N}$$

$$\text{Varianz: } \text{Var}(X) = n \cdot \frac{M}{N} \cdot \frac{N-M}{N} \cdot \frac{N-n}{N-1}$$

Beschreibt Situation des Ziehens ohne Zurücklegen.

### 14.4 Die Poisson-Verteilung

$$\text{Dichtefunktion: } f(x_i) = \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \quad \text{für } x_i = 0, 1, 2, \dots$$

$$\text{Schreibweise: } X \sim \text{Poi}(\lambda)$$

$$\text{EW und Varianz: } E(X) = \text{Var}(X) = \lambda$$

## 15 Stetige Verteilungen

### 15.1 Die stetige Gleichverteilung (Rechteckverteilung) auf $[a, b]$

$$\text{Dichtefunktion: } f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{sonst} \end{cases}$$

$$\text{Schreibweise: } X \sim G[a, b]$$

$$\text{Erwartungswert: } E(X) = \frac{a+b}{2}$$

$$\text{Varianz: } \text{Var}(X) = \frac{(b-a)^2}{12}$$

### 15.2 Die Normalverteilung

$$\text{Dichtefunktion: } f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$\text{Schreibweise: } X \sim N(\mu, \sigma^2)$$

$$\text{Erwartungswert: } E(X) = \mu$$

$$\text{Varianz: } \text{Var}(X) = \sigma^2$$

#### 15.2.1 Eigenschaften

- Standardnormalverteilung:
  - spezielle Normalverteilung  $N(0, 1)$  mit Parametern  $\mu = 0$  und  $\sigma^2 = 1$
  - Verteilungsfunktion:  $\Phi$
  - Speziell für die Verteilungsfunktion der Standardnormalverteilung gilt:
$$\Phi(-z) = P(Z \leq -z) = P(Z \geq z) = 1 - \Phi(z)$$
- für p-Quantil  $z_p$  gilt:  $z_{1-p} = -z_p$

- Standardisierung einer  $N(\mu, \sigma^2)$ -verteilten Zufallsvariable  $X$ , so dass Transformation  $Z \sim N(0, 1)$ -verteilt ist:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1), \text{ d.h. } P(Z \leq z) = \Phi(z).$$

- $X \sim N(\mu, \sigma^2), Y = aX + b \Rightarrow Y \sim N(a\mu + b, a^2 \cdot \sigma^2)$
- $X_1, \dots, X_n$  stochastisch unabhängig,  $X_i \sim N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$

### 15.2.2 Bestimmung von Wahrscheinlichkeiten $P(a \leq X \leq b)$

- Für eine  $N(0, 1)$ -verteilte Zufallsvariable  $Z$  ist

$$P(Z \leq z) = \Phi(z) \quad \text{und}$$

$$P(a \leq Z \leq b) = \Phi(b) - \Phi(a).$$

- Für eine  $N(\mu, \sigma^2)$ -verteilte Zufallsvariable  $X$  ist

$$P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right) \quad \text{und}$$

$$P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right).$$

### 15.2.3 Bestimmung von Quantilen

- p-Quantil  $z_p$  der  $N(0, 1)$ -Verteilung:  $z_p$  aus Tabelle
- p-Quantil  $x_p$  der  $N(\mu, \sigma^2)$ -Verteilung:  $x_p = \sigma \cdot z_p + \mu$ ,  $z_p$  aus Tabelle

## 15.3 t-Verteilung mit $n$ Freiheitsgraden (Student t-Verteilung)

Schreibweise:  $X \sim t_n$

- symmetrisch um 0
- für das p-Quantil gilt:  $t_{n;p} = -t_{n;1-p}$
- $X \sim t_n$  und  $n \geq 2 \Rightarrow E(X) = 0$
- $X \sim t_n$  und  $n \geq 3 \Rightarrow Var(X) = \frac{n}{n-2}$
- Für  $n \rightarrow \infty$  gilt  $t_n \rightarrow N(0, 1)$  (ca. ab  $n \geq 30$ )
- $X_1, \dots, X_n$  unabhängig und identisch  $N(\mu, \sigma^2)$ -verteilt  $\Rightarrow \sqrt{n} \cdot \frac{\bar{X} - \mu}{S} \sim t_{n-1}$

## 16 Schätzer

### 16.1 Schätzer für Erwartungswert und Varianz

$X_1, \dots, X_n$  Zufallsvariablen mit  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$

- Schätzer für  $\mu$ :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{mit} \quad E(\bar{X}) = \mu$$

zusätzlich ist  $Var(\bar{X}) = \frac{\sigma^2}{n}$ , falls die  $X_i$  unabhängig



- Schätzer für  $\sigma^2$ , falls die  $X_i$  unabhängig mit identischer Verteilung:

$$\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{mit} \quad E(\tilde{S}^2) = \frac{n-1}{n} \sigma^2$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{mit} \quad E(S^2) = \sigma^2$$

Hinweis: Verschiebungssatz siehe 4.4 und 4.6

## 16.2 Konfidenzintervalle für $\mu$ im Normalverteilungsmodell

Betrachte eine Zufallsvariable  $X$  mit  $X \sim N(\mu, \sigma^2)$ ; seien  $X_1, \dots, X_n$  unabhängig und identisch verteilt wie  $X$ .

Gegeben sei weiter eine Irrtumswahrscheinlichkeit  $\alpha, 0 < \alpha < 1$ .

- Falls  $\sigma^2$  bekannt, so ist

$$\left[ \bar{X} - \frac{\sigma}{\sqrt{n}} \cdot z_{1-\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} \cdot z_{1-\alpha/2} \right]$$

ein  $(1 - \alpha)$ -Konfidenzintervall für  $\mu$ .

Dabei bezeichnet  $z_{1-\alpha/2}$  das  $(1 - \alpha/2)$ -Quantil der  $N(0, 1)$ .

- Falls  $\sigma^2$  unbekannt ist, ist

$$\left[ \bar{X} - \frac{S}{\sqrt{n}} \cdot t_{n-1; 1-\alpha/2}, \bar{X} + \frac{S}{\sqrt{n}} \cdot t_{n-1; 1-\alpha/2} \right]$$

ein  $(1 - \alpha)$ -Konfidenzintervall für  $\mu$ .

Dabei ist  $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ , und  $t_{n-1; 1-\alpha/2}$  bezeichnet das  $(1 - \alpha/2)$ -Quantil der t-Verteilung mit  $n - 1$  Freiheitsgraden.

## 16.3 Approximative Konfidenzintervalle für $\mu$

Betrachte eine Zufallsvariable  $X$  mit  $E(X) = \mu$ ,  $Var(X) = \sigma^2$ ;

seien  $X_1, \dots, X_n$  unabhängig und identisch verteilt wie  $X$ , sei  $n \geq 30$ .

- Falls  $\sigma^2$  bekannt, so ist

$$\left[ \bar{X} - \frac{\sigma}{\sqrt{n}} \cdot z_{1-\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} \cdot z_{1-\alpha/2} \right]$$

ein approximatives  $(1 - \alpha)$ -Konfidenzintervall für  $\mu$ .

- Falls  $\sigma^2$  unbekannt, so ist

$$\left[ \bar{X} - \frac{S}{\sqrt{n}} \cdot t_{n-1; 1-\alpha/2}, \bar{X} + \frac{S}{\sqrt{n}} \cdot t_{n-1; 1-\alpha/2} \right]$$

ein approximatives  $(1 - \alpha)$ -Konfidenzintervall für  $\mu$ .

Dabei bezeichnet  $t_{n-1; 1-\alpha/2}$  das  $(1 - \alpha/2)$ -Quantil der t-Verteilung mit  $n - 1$  Freiheitsgraden.

# 17 Statistische Hypothesentests

## 17.1 Gauß-Test

Seien  $X_1, \dots, X_n$  unabhängige und identisch normalverteilte Zufallsvariablen,  $X_i \sim N(\mu, \sigma^2)$ , und sei  $\sigma^2$  **bekannt**.

Testproblem $H_0$ vs. $H_1$	Entscheidung
$\mu = \mu_0$ vs. $\mu \neq \mu_0$	Lehne $H_0$ ab, falls $\left  \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} \right  > z_{1-\alpha/2}$
$\mu \geq \mu_0$ vs. $\mu < \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} < -z_{1-\alpha}$
$\mu \leq \mu_0$ vs. $\mu > \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} > z_{1-\alpha}$

Dabei bezeichnet  $z_\alpha$  das  $\alpha$ -Quantil der Standardnormalverteilung.

## 17.2 t-Test

Seien  $X_1, \dots, X_n$  unabhängige und identisch normalverteilte Zufallsvariablen,  $X_i \sim N(\mu, \sigma^2)$ , und sei  $\sigma^2$  **unbekannt**.

Testproblem $H_0$ vs. $H_1$	Entscheidung
$\mu = \mu_0$ vs. $\mu \neq \mu_0$	Lehne $H_0$ ab, falls $\left  \sqrt{n} \frac{\bar{X} - \mu_0}{S} \right  > t_{n-1; 1-\alpha/2}$
$\mu \geq \mu_0$ vs. $\mu < \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{S} < -t_{n-1; 1-\alpha}$
$\mu \leq \mu_0$ vs. $\mu > \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{S} > t_{n-1; 1-\alpha}$

Dabei bezeichnet  $t_{n-1, \alpha}$  das  $\alpha$ -Quantil der t-Verteilung mit  $n - 1$  Freiheitsgraden.

## 17.3 Approximativer Gauß-Test

Seien  $X_1, \dots, X_n$  unabhängige und identisch verteilte Zufallsvariablen, die aber **nicht notwendig normalverteilt** sind, mit  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$ . Sei  $\sigma^2$  **unbekannt** und  $n \geq 30$ .

Testproblem $H_0$ vs. $H_1$	Entscheidung
$\mu = \mu_0$ vs. $\mu \neq \mu_0$	Lehne $H_0$ ab, falls $\left  \sqrt{n} \frac{\bar{X} - \mu_0}{S} \right  > z_{1-\alpha/2}$
$\mu \geq \mu_0$ vs. $\mu < \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{S} < -z_{1-\alpha}$
$\mu \leq \mu_0$ vs. $\mu > \mu_0$	$\sqrt{n} \frac{\bar{X} - \mu_0}{S} > z_{1-\alpha}$

## 17.4 Test auf einen Anteil

Ein Anteil  $p$  der Grundgesamtheit besitze eine interessierende Eigenschaft.

Seien  $X_1, \dots, X_n$  unabhängige und identisch verteilte Zufallsvariablen mit  $X_i = 1$ , falls das  $i$ -te Element die Eigenschaft besitzt,  $X_i = 0$  sonst.

Testproblem $H_0$ vs. $H_1$	Entscheidung
$p = p_0$ vs. $p \neq p_0$	Lehne $H_0$ ab, falls $\left  \sqrt{n} \frac{\bar{X} - p_0}{\sqrt{p_0 \cdot (1-p_0)}} \right  > z_{1-\alpha/2}$
$p \geq p_0$ vs. $p < p_0$	$\sqrt{n} \frac{\bar{X} - p_0}{\sqrt{p_0 \cdot (1-p_0)}} < -z_{1-\alpha}$
$p \leq p_0$ vs. $p > p_0$	$\sqrt{n} \frac{\bar{X} - p_0}{\sqrt{p_0 \cdot (1-p_0)}} > z_{1-\alpha}$

## 17.5 $\chi^2$ Unabhängigkeitstest

Betrachtet werden zwei Zufallsvariablen  $X, Y$ . Die Beobachtungspaare  $(x_i, y_i)$  seien in einer  $(k \times m)$ -Kontingenztafel zusammengefasst.

- Gemeinsame absolute Häufigkeiten in der Tafel:  $h_{ij}$
- Randhäufigkeiten:  $h_{i\cdot}$  bzw.  $h_{\cdot j}$
- Unter Unabhängigkeit von  $X$  und  $Y$  erwartete Häufigkeiten:

$$e_{ij} = \frac{h_{i\cdot} \cdot h_{\cdot j}}{n} \quad , \quad i = 1, \dots, k \quad , \quad j = 1, \dots, m$$

Testproblem:  **$H_0 : X, Y$  unabhängig** vs.  **$H_1 : X, Y$  abhängig**

Entscheidungsregel:  $H_0$  wird zum Niveau  $\alpha$  verworfen, falls

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - e_{ij})^2}{e_{ij}} > \chi_{(k-1) \cdot (m-1); 1-\alpha}^2$$

Dabei bezeichnet  $\chi_{q;\alpha}^2$  das  $\alpha$ -Quantil der  $\chi^2$ -Verteilung mit  $q$  Freiheitsgraden.